


Do clique ao Data Warehouse

Monitoramento de vendas e logística de um e-commerce, combinando streaming e batch.

GRUPO 9

Arisio Soares Andrade Filho · Raul De Queiroz Moura · José Kayky Barbosa Coelho · Levi Marques Waterloo
· Carlos Neuan Sampaio Silva

Um evento entra uma vez e segue dois caminhos



Streaming para reagir em segundos; batch para consolidar o histórico.

Python e Flume: um evento, duas cópias

Gerador Python

- Loop infinito: cliques, carrinho, checkout e entrega
- Saída em JSON, uma linha por evento
- ~5% de eventos atrasados, de propósito

Flume, com fan-out

- Source exec: tail -F no log
- Um channel por sink, senão os sinks disputam os eventos
- Sink 1: HDFS (bruto). Sink 2: arquivos rolados a cada 5 s para o Flink

```
docker compose logs -f generator

$ docker compose logs -f generator

{"event_id": "d4117fc5-f6e5-4b30-b58e-dd75272d601e", "timestamp": "2026-09-23T17:12:06.864375+00:00", "user_id": 1006, "product_id": 203, "product_name": "Fritadeira Elétrica Airfryer", "category": "Eletrodomésticos", "action": "click", "price": 399.9, "delivery_status": null}

{"event_id": "717a5d93-669e-479e-aebd-ff4b744fcabe", "timestamp": "2026-09-23T17:12:07.605711+00:00", "user_id": 1047, "product_id": 302, "product_name": "Calça Jeans Slim", "category": "Vestuário", "action": "add_to_cart", "price": 149.9, "delivery_status": null}
```

```
flume/flume.conf

agent.channels = c1 c2
# copia cada evento para TODOS os channels; um channel por sink garante fan-out
agent.sources.r1.command = tail -F /logs/ecommerce_events.log
agent.sources.r1.channels = c1 c2
agent.channels.c1.type = memory
agent.channels.c1.capacity = 10000
agent.channels.c1.transactionCapacity = 1000
agent.channels.c2.type = memory
agent.channels.c2.capacity = 10000
agent.channels.c2.transactionCapacity = 1000
agent.sinks.k1.type = hdfs
agent.sinks.k1.channel = c1
agent.sinks.k1.hdfs.path = hdfs://namenode:9000/raw/events/%Y-%m-%d/
agent.sinks.k2.type = hdfs
agent.sinks.k2.channel = c2
agent.sinks.k2.hdfs.path = file:///logs/flink_stream
```

Flink: tendências em janelas deslizantes

Por que Flink e não só Spark Streaming?

- Evento a evento, latência baixa
- Tempo de evento e watermarks nativos
- Spark Streaming trabalha em micro-batches

5 min

janela deslizante,
passo de 1 min

30 s

atraso tolerado
(watermark)

≥ 10

cliques geram
alerta de
tendência

The screenshot displays the Apache Flink Dashboard interface. On the left is a sidebar with navigation links: Overview, Jobs, Running Jobs (selected), Completed Jobs, Task Managers, Job Manager, and Submit New Job. The main panel shows details for the job 'Ecommerce_TrendTopics_Flink_Job'. It includes a table with job metadata:

Job ID	434ab6f0c604a22bfe259f04fb1343	Job State	RUNNING 2	Actions	Job Manager Log
Start Time	2026-09-23 13:30:27	Duration	45m 37s		

Below the metadata, there are tabs for Overview, Exceptions, TimeLine, Checkpoints, and Configuration. The Overview tab is active, showing a job graph with two nodes:

- Source: EcommerceLogSource**: Map, Filter, Extract-Timestamp, p -> Timestamp/Watermarks -> Remove-Timestamp -> _stream_key_by_map_operator. Parallelism: 1. Backpressure (max): 0%, Busy (max): 2%.
- Sink: SlidingEventTimeWindows, Map**: p -> Sink: Print to Std. Out. Parallelism: 1. Backpressure (max): 0%, Busy (max): 0%, Low Watermark: 1750153723376.

The nodes are connected by a 'HASH' join. At the bottom, a table provides performance metrics for each task:

Name	Status	Bytes Received	Records Received	Bytes Sent	Records Sent	Parallelism	Tasks
Source: EcommerceLogSource -> Map, Filter, Extract-Timestamp -> T...	RUNNING	0 B	0	1.69 MB	5,903	1	1
SlidingEventTimeWindows, Map -> Sink: Print to Std. Out	RUNNING	1.69 MB	5,903	0 B	0	1	1

Spark: ETL sobre o histórico e Data Warehouse no Hive

Wide dependencies (shuffle)

- groupBy por produto: cliques, checkouts, receita e taxa de conversão
- join entre compras e status de entrega: resumo de logística

Do HDFS ao Hive

- Lê o histórico bruto do HDFS (dia anterior)
- Grava tabelas Parquet no Data Warehouse: fact_product_performance e fact_logistics_summary

```
spark/spark_etl_batch.py

product_metrics_df = events_df.groupBy("category", "product_id", "product_name") \
user_logistics_df = checkouts_df.join(
).groupBy("dt", "delivery_status") \
.format("parquet") \
.saveAsTable("ecommerce_dw.fact_product_performance")
.format("parquet") \
.saveAsTable("ecommerce_dw.fact_logistics_summary")
```

Por que HBase e não só HDFS?

	HDFS	HBase
Bom para	Gravar muito dado bruto e ler em sequência	Ler e gravar registros por chave, em baixa latência
No projeto	Logs brutos dos eventos	Alertas de tendência do Flink
Quem usa	Spark, em lote	Consulta imediata dos alertas
Ponto fraco	Ruim para acesso pontual	Não serve para varrer todo o histórico

Os alertas precisam ser consultados na hora, por chave (produto + janela). Os logs brutos, que serão varridos em lote, ficam no HDFS.

DEMONSTRAÇÃO

Do clique ao Data Warehouse, ao vivo

1. HDFS

```
namenode

$ hdfs dfs -ls -R /raw/events

-rw-r--r--  27927 17:07 events-.1790183185807.log
-rw-r--r--  26367 17:08 events-.1790183246177.log
-rw-r--r--  28188 17:09 events-.1790183306914.log
-rw-r--r--  27199 17:10 events-.1790183370019.log
-rw-r--r--  26063 17:11 events-.1790183432949.log
-rw-r--r--   2705 17:11 events-.1790183493495.log.tmp
```

`hdfs dfs -ls -R /raw/events`

2. HBase

```
hbase shell

$ scan 'ecommerce_alerts', {LIMIT => 1}

301_1790182020000 column=cf_alerts:is_trend, value=True
301_1790182020000 column=cf_metrics:click_count, value=54
301_1790182020000 column=cf_metrics:product_id, value=301
301_1790182020000 column=cf_metrics>window_end, value=2026-09-23 16:47:00
301_1790182020000 column=cf_metrics>window_start, value=2026-09-23 16:42:00
```

`scan 'ecommerce_alerts'`

3. Hive

```
beeline

$ SELECT product_name, clicks, receita, conv FROM fact_product_performance

+-----+-----+-----+-----+
| product_name | clicks | receita | conv |
+-----+-----+-----+-----+
| Fritadeira Elétrica Airfryer | 486 | 32792.0 | 16.9 |
| Geladeira Frost Free | 485 | 262200.0 | 14.2 |
| Calça Jeans Slim | 478 | 10343.0 | 14.4 |
| Micro-ondas 30L | 447 | 55250.0 | 19.0 |
| Camiseta Algodão | 435 | 3654.0 | 14.0 |
+-----+-----+-----+-----+
```

`SELECT ... FROM fact_product_performance`

Decisões que fizeram o pipeline fechar

Flink não faz tail de arquivo

O FileSource quebra com um arquivo que cresce. O Flume passou a rolar arquivos e o Flink monitora a pasta.

Sinks disputavam eventos

Dois sinks no mesmo channel dividem os eventos. Agora há um channel por sink.

Conexão com o HBase caía

As janelas disparam de minuto em minuto e a conexão ficava ociosa. O sink reconecta e repete a gravação.

Subida na ordem certa

Healthcheck no Postgres do Hive e restart automático mantêm a subida do zero sem intervenção manual.